

1 IDENTIFICAÇÃO DO PROJETO

TCC I - Turma 2024/1 semestre

Referência do projeto: 2024a_TCC1_Ianca Polizelo

Título: Aproximação de parâmetros de *clustering* em redes complexas e complexidade de amostra

Equipe:

Código do aluno: 1985388

Nome: Ianca Polizelo

Email: iancapolizelo@alunos.utfpr.edu.br

Telefone de contato: (41) 99287-7878

Professores Orientadores:

Profa. Dra. Alane Marie de Lima - DAINF

Prof. Dr. Leandro Zatesko - DAINF

Resumo:

Reconhecer grafos que constituem uma rede de mundo pequeno é uma atividade importante em teoria de grafos, pois essas redes possuem características de muitas redes de fenômenos naturais e podem ser utilizadas como modelos representativos deles. Existem algumas estratégias que podem ser adotadas para se identificar tais grafos, sendo uma delas o coeficiente de clustering local. Apesar de ser uma métrica relativamente nova, existem vários algoritmos já propostos com o intuito de se computar seu valor. Há uma variedade de abordagens utilizadas para se alcançar esse objetivo, alguns através de algoritmos exatos tendo como chave o problema de contagem de triângulos. Porém, possuindo complexidade computacional inviável quando pensamos em grafos de redes complexas. Também há um grande leque de opções quando pensamos em algoritmos de aproximação, utilizando das mais variadas estratégias de amostragens. Apesar dessa miríade de algoritmos, no trabalho de Lima et al. (2022) é apresentado um algoritmo que utiliza a teoria de complexidade de amostra para não apenas aprimorar a complexidade de execução, mas também para tornar o algoritmo mais bem adaptado para a estrutura combinatória de cada entrada. Neste presente trabalho, pretende-se de implementar esse algoritmo e realizar uma revisão bibliográfica sobre toda a fundamentação teórica necessária para se entender plenamente o funcionamento do algoritmo.

Palavras-chave: *Coeficiente de Clustering Local. VC Dimension. Complexidade de amostra. Teoria de Grafos. Redes Complexas.*

2 DESCRIÇÃO DO PROJETO / CARACTERIZAÇÃO

2.1 Objetivo Geral

Implementar um algoritmo de aproximação para o cálculo do coeficiente de *clustering* local em grafos que representam redes complexas, realizando estudos de comparações com algoritmos exatos utilizados para a computação de tal medida.

2.2 Objetivos Específicos

- Implementar algoritmo de aproximação para o cálculo do coeficiente de *clustering* local proposto por Lima et al. (2022) [1] utilizando linguagem de programação *Python*.
- Realizar uma análise exploratória na base de dados disponibilizada.
- Aplicar o algoritmo implementado e algoritmos exatos na base de dados disponibilizada.
- Realizar estudos de comparação entre os resultados obtidos em cada um dos algoritmos utilizados.
- Realizar revisão bibliográfica sobre a área de teoria de grafos e complexidade de amostra, e disponibilizar material em língua portuguesa para disseminação desse conhecimento científico.

2.3 Escopo

O objetivo deste trabalho é implementar o algoritmo de aproximação proposto por Lima et al. (2022) para calcular o coeficiente de *clustering* local em grafos utilizando-se da teoria de complexidade de amostra para selecionar a amostra necessária e suficiente do grafo para o cálculo.

2.3.1 Coeficiente de *Clustering* Local

A existência de agrupamentos ou *clusters* em redes complexas foi o que motivou a criação de uma variedade de métricas com a intenção de quantificar sua prevalência, sendo uma delas o coeficiente de *clustering* [2]. Existem duas variações dessa medida, a global e a local.

O coeficiente de *clustering* global quantifica o agrupamento geral de um grafo em termos do número de triângulos existentes. Ele se baseia em conjuntos de três vértices chamados trio. Um trio é composto por três vértices conectados por duas – chamado trio aberto – ou três – chamado trio fechado – arestas não direcionadas. Um triângulo consiste em três trios fechados, um em cada vértice. Portanto, o coeficiente de *clustering* global calcula a razão entre o número total de trios fechados e o número total de trios, abertos ou fechados [3]. Porém, se o objetivo é analisar algumas características mais específicas como modularidade, estrutura de comunidade, entre outras, o conceito de coeficiente *clustering* local se adequa melhor a necessidade [4]. Assim, como o objetivo desse trabalho está focado nessa outra medida, ela será abordada de forma mais profunda.

O coeficiente de *clustering* local é uma medida importante que quantifica a tendência de formação de grupos (ou clusters) entre os nós de um grafo. Ela é uma métrica que avalia a densidade de conexões entre os vizinhos de um nó específico v_i em um grafo, e fornece uma medida da probabilidade de que dois vizinhos desse nó estejam também conectados entre si, formando um triângulo no grafo. Ao analisar um grafo que modela uma rede social, por exemplo, onde cada nó simboliza uma pessoa e cada aresta representa um relacionamento entre duas pessoas, o coeficiente de *clustering* local pode ser utilizado para medir a probabilidade de que uma pessoa forme comunidades dentro dessa rede. Isso é feito estimando a chance de que dois amigos de uma pessoa também se tornem amigos entre si [5]. Esta medida foi originalmente proposta por Watts e Strogatz em 1998 para determinar se um grafo constitui uma rede de mundo pequeno.

Um grafo $G = (V, E)$ é composto, formalmente, por um conjunto de vértices V e de um conjunto de arestas E , onde a aresta e_{ij} conecta o vértice v_i ao vértice v_j . A vizinhança de N_i para um vértice v_i inclui todos os seus vértices adjacentes e as arestas que os conectam, ou seja, a vizinhança abrange todos os nós diretamente ligados. E definimos k_i como sendo o número de vértices de N_i . [6]. Em termos matemáticos, temos que:

$$N_i = \{v_j : e_{ij} \in E \wedge e_{ji} \in E\}$$

$$k_i = |N_i|$$

A definição formal do coeficiente de *clustering* local é definida pela razão entre o número de arestas existentes entre os vizinhos de v_i e o número total de arestas possíveis entre esses vizinhos. O número de arestas existentes entre os vizinhos de v_i é dado por E_i . O número máximo de arestas possíveis entre os k_i vizinhos de v_i é:


$$\frac{k_i(k_i - 1)}{2}$$

Sendo assim, o coeficiente de *clustering* local C_i é então definido como:

$$C_i = \frac{2E_i}{k_i(k_i - 1)}$$

Este coeficiente varia entre 0 e 1, onde 0 indica que nenhum dos vizinhos de v_i estão conectados entre si e 1 indica que todos os vizinhos de v_i estão completamente conectados, formando um clique [7].

Abaixo está uma figura exemplificando o cálculo para o vértice em azul, onde as arestas em destaque preto são as arestas existentes entre seus vizinhos e as arestas tracejadas em vermelhos são as possíveis arestas entre os vizinhos.



Um valor alto de C_i sugere uma forte coesão local, onde os vizinhos de v_i tendem a formar um subgrafo densamente conectado. Isso é comum em redes sociais, onde amigos de um indivíduo tendem a ser também amigos entre si.

2.3.2 Algoritmo de Aproximação

Existe uma variedade de algoritmos já propostos que buscam computar o coeficiente de *clustering* local de um grafo, tanto tendo abordagens para cálculos exatos quanto para cálculos aproximados.

Os algoritmos exatos propostos para calcular o coeficiente de *clustering* local de cada vértice de um grafo estão estreitamente relacionados ao problema de contagem de triângulos locais, já que este último pode ser transformado no primeiro [8]. Um algoritmo de “força bruta” que lista todos os trios de vértices para verificar quantos deles possui triângulos executa em tempo cúbico. O algoritmo proposto por Alon et al. (1997) melhora esse tempo de execução para $O(m^{2w/(w+1)})$, onde $m = |E|$ e w é 2,373, o expoente da multiplicação de matrizes [9]. Já o algoritmo proposto por Chiba e Nishizeki et al. (1985) melhora esse tempo de execução para $O(\alpha(G) \cdot m)$, onde $\alpha(G)$ é a arborescência do grafo G . Como $\alpha(G) = O(\sqrt{m})$, esse algoritmo executa em $O(m^{3/2})$ no pior caso [10].

Porém, tendo o cenário que a entrada é um grafo que modela uma rede complexa, onde o grau é na casa dos milhares, utilizar esses algoritmos exatos se torna computacionalmente inviável. Logo, algumas abordagens de aproximação que são mais rápidas se fazem mais interessantes. Uma dessas abordagens é o algoritmo proposto por Kutzkov e Pagh em 2013, onde os autores apresentam um algoritmo de streaming com ε -aproximação para estimar, com probabilidade de $1 - \delta$, o coeficiente de *clustering* local de cada vértice com grau pelo menos d em tempo esperado $O(\frac{m}{\alpha \varepsilon^2} \log \frac{1}{\varepsilon} \log \frac{n}{\delta})$, onde $n = |V|$ e α é o coeficiente de *clustering* local desse vértice. Nesse caso ε e δ são tratados como constantes. [11] Temos também a abordagem de contagem de triângulos locais em algoritmos de aproximação como o apresentado por Becchetti et al. em 2010: um algoritmo de semi-streaming para calcular uma aproximação com erro relativo do

número de triângulos de cada vértice de um grafo em tempo $O(m \cdot k)$, onde k é o número de passagens sobre os dados no algoritmo [12]. Uma excelente revisão sobre esses métodos, incluindo algoritmos exatos e de aproximação, para o problema de contagem global de triângulos foi feita por Al Hasan e Dave em 2018 [13].

Uma abordagem que pode ser utilizada para algoritmos de aproximação é a teoria de complexidade de amostra para se obter melhores resultados. O algoritmo proposto por Lima et al. (2022) – que é o objeto de estudo deste trabalho, tendo como objetivo implementá-lo – faz uso da *VC-Dimension* e ε -sample, onde amostra arestas de um grafo de entrada G e, para constantes fixas $0 < \varepsilon, \delta, p < 1$, fornece uma estimativa $l'(v)$ para o valor exato $l(v)$ do coeficiente de *clustering* local de cada vértice $v \in V$. Os resultados respeitam $|l(v) - l'(v)| \leq \varepsilon l(v)$, com probabilidade de pelo menos $1 - \delta$ sempre que $l(v)$ for pelo menos $\frac{pm}{2\delta_v}$, onde δ_v é o grau de v [14]. A utilização da *VC-Dimension* e ε -sample ao invés de abordagens clássicas da literatura, como o limitante da união, para algoritmos de amostragem é em decorrência da importância que a estrutura combinatória das entradas se faz presente neles.

Existe também um algoritmo proposto por Zhang et al. em 2015 que busca computar os top- k vértices com maiores coeficientes de *clustering* local de um grafo e utiliza *VC-Dimension* e o teorema ε -sample [15], porém em um contexto e espaço de intervalos diferentes do proposto por Lima et al. (2022)

2.3.3 Complexidade de Amostra

Toda a fundamentação teórica dessa seção terá como referência o livro “Understanding Machine Learning: From Theory to Algorithms” [16].

A teoria da complexidade de amostras é uma área fundamental em aprendizagem de máquina e teoria da computação. Um dos conceitos centrais nessa área é a dimensão de Vapnik-Chervonenkis, também conhecida como *VC-Dimension*. Ela é uma medida combinatória utilizada para expressar a complexidade de um conjunto de funções e está intimamente relacionada à capacidade de um modelo de aprendizagem generalizar bem a partir de amostras.

Para melhor definir a *VC-Dimension*, é necessário antes entender também a definição de Range Space.

- **Range Space:** é um par $R = (X, \mathcal{I})$, onde X é o domínio e o $\mathcal{I}$ um subconjunto de X , chamados ranges. Em termos de aprendizagem de máquina, X pode ser visto como um conjunto de pontos dados e $\mathcal{I}$ como uma coleção de subconjuntos de X que podem ser “alcançados” por um modelo de aprendizagem, isto é, as diferentes classificações possíveis dos pontos dados.
- **VC Dimension:** a dimensão VC de um *range space* $R = (X, \mathcal{I})$, denotado por $VCDim(R)$, é o tamanho máximo de um conjunto de pontos que pode ser completamente “particionado” por R . Aqui, “particionado” significa que, para qualquer partição possível dos pontos em duas classes, como positivo e negativo, existe uma função em R que pode realizar exatamente essa partição. Em termos matemáticos, temos que:


$$VCDim(R) = \max \{d: \exists S \subseteq X \text{ tal que } |S| = d \text{ e } |\mathcal{I}_S| = 2^d \}$$

A definição acima não implica que todo conjunto de cardinalidade d é particionado por $\mathcal{I}$, porém se for mostrado que todos os conjuntos de cardinalidade de pelo menos $d + 1$ não é particionado por $\mathcal{I}$, então a $VCDim(R)$ não é maior que d .

Para exemplificar melhor o cálculo da dimensão VC é possível observar o conjunto de funções lineares em R^2 :

Seja $R = (X, \mathcal{I})$ um *range space* onde $X = \mathbb{R}^2$ e $\mathcal{I}$ é o subconjunto de funções lineares no $\mathbb{R}^2$. Então temos que $\text{VCDim}(R) = 3$. Abaixo está a prova:


Primeiro é necessário mostrar que $\text{VCDim}(R) \geq 3$ através das imagens abaixo, onde existe um conjunto de três pontos não colineares que são participados por $\mathcal{I}$:




Na imagem acima é possível verificar que os três pontos podem ser totalmente particionados utilizando um conjunto de funções lineares em todas as possibilidades de particionamento.

Agora, também é necessário mostrar que $\text{VCDim}(R) < 4$. Para isso, é preciso considerar três casos:

- Um conjunto de três pontos colineares não pode ser totalmente particionado em duas categorias diferentes, visto que não existe uma maneira de separar o ponto médio entre os outros dois pontos por nenhuma função linear.
- Um ponto que está dentro do fecho convexo definido por outros três pontos. Este conjunto não pode ser totalmente particionado por uma função linear, visto que não existe meio de separar o ponto interno dos demais pontos.



- Um conjunto de quatro pontos que define um fecho convexo não pode ser totalmente particionado, visto que não existe maneira de separar os pontos em vermelho dos pontos em azul por uma função linear, conforme demonstrado na figura abaixo:



Sendo assim, temos então que $\text{VCDim}(R) = 3$.

Compreender a *VC-Dimension* é crucial para analisar a capacidade de generalização de modelos de aprendizagem de máquina. Ela fornece uma medida de quão complexos são os padrões que um modelo pode capturar e isso está diretamente relacionado à probabilidade do modelo de realizar uma boa generalização em novos dados.

A fim de aplicar essa métrica na amostra e conseguir verificar o tamanho necessário dela, e relacioná-la com a aproximação, existem a definição e teorema a seguir.

A (p, ε) -aproximação relativa é útil no contexto em que se deseja encontrar uma amostra $S \subseteq X$ que estime o tamanho dos intervalos em $\mathcal{I}$, em relação a um parâmetro ajustável p , dentro de $\varepsilon Pr_\pi(I)$, para $0 < \varepsilon, p, \delta < 1$. Isso ocorre com probabilidade pelo menos $1 - \delta$, para $0 < \delta < 1$, onde π é uma distribuição sobre X e $Pr_\pi(I)$ é a probabilidade de uma amostra de π pertencer a I . A definição formal de (p, ε) -aproximação relativa é dada por:

- **Definição 1** ((p, ε) -aproximação relativa, (Riondato e Kornaropoulos (2016)), Definição 5). Dado $0 < \varepsilon, p, \delta < 1$, um conjunto S é chamado de (p, ε) -aproximação em relação a um espaço de intervalos $R = (X, \mathcal{I})$, e uma distribuição π sobre X se para todo $I \in \mathcal{I}$,

$$(i) \left| Pr_\pi(I) - \frac{|S \cap I|}{|S|} \right| \leq \varepsilon Pr_\pi(I), \quad \text{se } Pr_\pi(I) \geq p,$$

$$(ii) \frac{|S \cap I|}{|S|} \leq (1 + \varepsilon)p, \quad \text{senão}$$

Um limite superior para a *VC-Dimension* de um espaço de intervalos permite construir uma amostra S que é um conjunto de (p, ε) -aproximação.

- **Teorema 1** (Har-Peled e Sharir (2011), Teorema 5). Dado $0 < \varepsilon, p, \delta < 1$, seja

$R = (X, \mathcal{I})$ um range space com $VCDim(R) \leq d$, uma distribuição dada π sobre X , e seja c uma constante positiva universal. Uma coleção $S \subseteq X$ amostrada em relação a π com $|S| \geq \frac{c}{\varepsilon^2 p} \left(d \log \frac{1}{p} + \log \frac{1}{\delta} \right)$ é uma (p, ε) -aproximação relativa com probabilidade de pelo menos $1 - \delta$, onde c é uma constante positiva absoluta.

3 MOTIVAÇÃO E RESULTADOS ESPERADOS

3.1 Motivação/Justificativa Resumida

O coeficiente de *clustering* local foi inicialmente proposto com a intenção de determinar se um grafo qualquer possuía a propriedade de ser um grafo de mundo pequeno [17]. Esses grafos possuem algumas características que os tornam muito importantes quando estudamos conceitos de redes sociais e fenômenos de contágio de doenças. Eles possuem alta coesão local [18], ou seja, os nós tendem a formar grupos ou *clusters* densamente conectados, e possuem baixa distância média [19], logo, a distância média entre dois nós quaisquer no grafo é relativamente pequena, mesmo que o número total de nós no grafo seja muito grande. Isso significa que a maioria dos nós pode ser alcançado a partir de qualquer outro nó através de um pequeno número de etapas.

Essas características são de extrema importância quando estudamos redes sociais ou redes de transporte, por exemplo. Isso porque existe uma eficiência de comunicação, pois a baixa distância média facilita a rápida disseminação de informações. Assim como também existe robustez e resiliência nessas estruturas, significando que falhas em parte da rede não necessariamente desconectam toda a rede, pois há caminhos alternativos dentro dos *clusters*. Grafos de mundo pequeno são úteis para modelar fenômenos naturais e sociais como a propagação de doenças, a disseminação de ideias e tendências entre vários outros fenômenos [20]. Logo, existir um algoritmo que calcule essa métrica de forma muito aproximada dos exatos, porém em tempo muito menor faz-se muito importante.

Mais do que a própria importância do coeficiente de *clustering* local, uma das motivações para a implementação do algoritmo proposto por Lima et al. (2022) – além do próprio fato de ser um algoritmo novo sem nenhuma implementação realizada antes – é o diferencial pela utilização da teoria de complexidade de amostras em um algoritmo de amostragem. Uma das vantagens de se utilizar a métrica da *VC-Dimension* de teoria de complexidade de amostra é que é possível obter um limite superior para o tamanho da amostra que é mais restrito do que os fornecidos pelas técnicas padrão de amostragem de Hoeffding e limitante da união [21]. Além disso, esses limitantes clássicos da literatura para algoritmos de amostragem, como limitante da união, Chernoff e Chebyshev, limitam-se ao tamanho da entrada e não levam em conta a estrutura combinatória de cada entrada, como a *VC-Dimension* faz no contexto de complexidade de amostras [22].

Outro grande fator motivador deste trabalho é a falta de material científico em português dentro da área de teoria de grafos e teoria de complexidade de amostra, tornando o desenvolvimento do conhecimento dessa área muito limitado dentro do Brasil por conta de sua inacessibilidade.

3.2 Resultados Esperados (tecnológicos, científicos, econômicos, sociais e/ou ambientais)

Os principais resultados esperados são:

- Implementar e disponibilizar em repositório público no *GitHub* o algoritmo proposto por Lima et al. (2022) em linguagem *Python* 3.10 ou superior para contribuir com a comunidade tecnológica.
- Dimensionar a performance do algoritmo implementado através da realização de estudos de comparação com outros algoritmos já implementados para a computação do coeficiente de *clustering* local que tenham utilizado a mesma linguagem e biblioteca utilizadas na implementação deste trabalho.
- Fornecer material acadêmico em português do Brasil sobre teoria de grafos e teoria de complexidade de amostra através da monografia final do trabalho.

4 METODOLOGIA E MECANISMOS DE GESTÃO

4.1 Metodologia

Pode-se dividir o trabalho em 4 fases:

1. Fundamentação teórica: como um dos objetivos do trabalho é a disponibilização de material em português das áreas estudadas, deverá ser conduzido um estudo teórico de artigos e teses publicados relacionados ao tema de teoria de grafos e teoria de complexidade de amostras. Essa revisão bibliográfica deve ser escrita em português do Brasil em uma linguagem de fácil acesso para estudantes de nível de graduação na área de computação.
2. Implementação do algoritmo de aproximação proposto por Lima: deve-se utilizar linguagem de programação *Python* 3.10 ou superior e biblioteca *NetworkX* para manipulação de grafos.
3. Aplicação dos algoritmos na base de dados: após a implementação do algoritmo, será necessário aplicá-lo em uma base de dados, assim como também a aplicação de outros algoritmos já implementados com o mesmo intuito de computar o coeficiente de *clustering* local. A base de dados utilizada será fornecida pelos professores orientadores, tendo em vista que será a mesma utilizada para os estudos e implementações realizadas na tese de Lima.
4. Análise, interpretação e comparação dos resultados: após a aplicação dos algoritmos, deverá ser feita uma série de estudos de comparação entre as performances do algoritmo de aproximação implementado e os demais algoritmos exatos já existentes, dando enfoque em métricas de tempo.

4.2 Análise de Riscos

Os principais riscos para o projeto estão descritos abaixo:

Risco 1

Importância: Alta.

Descrição: Comunicação insatisfatória entre membros da equipe e orientadores.

Efeito no Projeto: Atraso no desenvolvimento do projeto.

Probabilidade: Baixa.

Impacto: Alto.

Ação: Mitigar: Estabelecer reuniões semanais e promover contatos frequentes.

Risco 2

Importância: Alta.

Descrição: Qualidade insatisfatória dos dados utilizados.

Efeito no Projeto: Resultados pouco substanciados.

Probabilidade: Baixa.

Impacto: Médio.

Ação: Eliminar: Utilizar a mesma fonte de dados que foi utilizada por Lima em sua tese de doutorado.

Risco 3

Importância: Média.

Descrição: Falta de conhecimento técnico de modelos para análises e utilização de ferramentas.

Efeito no Projeto: Atraso no desenvolvimento do projeto.

Probabilidade: Média.

Impacto: Baixo.

Ação: Eliminar: Procurar conhecimento técnico orientado por doutores na área.

Risco 4

Importância: Baixa.

Descrição: Indisponibilidade do aluno por doença/procedimento cirúrgico.

Efeito no Projeto: Atraso no desenvolvimento do projeto.

Probabilidade: Alta.

Impacto: Baixo.

Ação: Eliminar: Elaborar cronograma adequado que comporte período de atestado médico.

4.3 Cronograma, Datas Importantes e Responsabilidades das Ações e Custos

O cronograma simplificado exibido abaixo, aborda os meses em que serão realizadas as etapas descritas na seção de Metodologia, durante o desenvolvimento do projeto. Abaixo deste encontra-se o cronograma detalhado, com o total de horas dedicadas para cada ação de cada etapa do projeto.

4.3.1 Cronograma Simplificado:

Etapa		2024 (Meses)							
		5	6	7	8	9	10	11	12
1	Estudo de artigos relacionados ao tema	X	X	X	X	X	X	X	X
2	Implementação do algoritmo de aproximação		X	X	X				
3	Análise exploratória nos dados disponibilizado		X	X	X				
4	Aplicação dos algoritmos na base de dados				X	X			
5	Análise, interpretação e comparação dos resultados obtidos				X	X	X		
6	Documentação e escrita do projeto	X	X	X	X	X	X	X	X
7	Defesa e entrega do projeto finalizado								X

4.3.2 Cronograma Detalhado:

Etapa	Ação	Entregável	Início	Fim	Horas Dedicadas
1	Análise de materiais acadêmicos sobre teoria de grafos, teoria de complexidade de amostras e aprendizagem de máquina.	Estudo detalhado	25/03	01/11	100
2	Análise detalhada do algoritmo de Lima et al. (2022)	Estudo detalhado	24/06	08/07	5
	Escrita do código para implementação do algoritmo de Lima et al. (2022)	Código versionado no GitHub	08/07	12/08	20
3	Visualização dos dados de formas variadas	Apresentação de gráficos	24/06	12/08	5
4	Aplicação do algoritmo implementado sobre os dados pelo menos 10 vezes	Dados para análise	12/08	30/08	10
	Aplicação de pelo menos outros 2 algoritmos sobre os dados, no mínimo 10 vezes cada	Dados para análise	30/08	30/09	20
5	Estudos de comparação entre os dados obtidos das aplicações dos algoritmos	Texto detalhado	12/08	10/10	10

6	Escrita, documentação e resultados	Trabalho final	01/05	01/12	200
7	Defesa e entrega do projeto finalizado	Trabalho final	01/12	01/12	2
	Correções finais no texto	Trabalho final	02/12	15/12	20
				Total de Horas:	392

4.3.3 Custos

As análises deste projeto serão todas feitas com ferramentas de uso gratuito, e os *datasets* utilizados serão disponibilizados pelos professores orientadores. Portanto, não haverá custos associados à realização deste projeto.

5 DOCUMENTAÇÃO

5.1 Estrutura do Sumário

Abaixo se encontra a estrutura de sumário proposta para o projeto:

1. Introdução
 - 1.1. Motivação
 - 1.2. Objetivos
 - 1.3. Estrutura do Documento e Metodologia
2. Fundamentação teórica
 - 2.1. Preliminares em Grafos
 - 2.2. *VC-Dimension* e *Range Space*
 - 2.3. ϵ -sample
 - 2.4. Coeficiente de *Clustering Local*
 - 2.5. Algoritmos
3. Análise Exploratória
 - 3.1. Organização de *dataset*
4. Implementação
5. Aplicação dos algoritmos no *dataset*
6. Comparação entre algoritmos
 - 6.1. Resultados Obtidos
 - 6.2. Limitações
7. Considerações Finais
 - 7.1. Trabalhos futuros
 - 7.2. Considerações

5.2 Referências

1. LIMA, Alane Marie de, 2022. *Approximation Algorithms in Graphs via Sample Complexity*. Universidade Federal do Paraná, p.70.
2. ALBERT, R. and BARABÁSI, A. L., 2002. *Statistical Mechanics of Complex Networks*. Rev. Mod. Phys, 74(1), pp.69-70.
3. ALBERT, R. and BARABÁSI, A. L., op. cit., pp.48-49.
4. LIMA, op. cit., p.63.
5. LIMA, op. cit., p.11.
6. EASLEY, David and KLEINBERG, Jon, 2010. *Networks, Crowds, and Markets: Reasoning about a Highly Connected World*. Cambridge University Press, pp.23-24
7. ALBERT, R. and BARABÁSI, A. L., op. cit., p.49.
8. LIMA, op. cit., p.64.
9. ALON, N., YUSTER, R. and ZWICK, U., 1997. *Finding and counting given length cycles*. Algorithmica, 17(3), pp.209-223.
10. CHIBA, N. and NISHIZEKI, T., 1985. *Arboricity and Subgraph Listing Algorithms*. SIAM Journal on computing, 14(1), p.210-223.
11. KUTZKOV, K. and PAGH, R., 2013. *On the streaming complexity of computing local clustering coefficients*. Proceedings of the sixth ACM international conference on Web search and data mining, p.677-686.
12. BECCHETTI, L., BOLDI, P., CASTILLO, C. and GIONIS, A., 2010. *Efficient algorithms for large-scale triangle counting*. ACM Transactions on Knowledge Discovery from Data (TKDD), 4(3), pp.1-28.
13. AL HASAN, M. and DAVE, V. S., 2018. *Triangle counting in large networks: a review*. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 8(2).
14. LIMA, op. cit., pp.64-65.
15. ZHANG, J., TANG, J., MA, C., TONG, H., JING, Y. and LI, J., 2015. *Panther: Fast top-k similarity search on large networks*. Proceeding of the 21th ACM SIGKDD international conference on knowledge discovery and data mining, pp.1445-1454.
16. SHALEV-SHWARTZ, S. and BEN-DAVID, S., 2014. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.
17. WATTS, D. J. and STROGATZ, S. H., 1998. *Collective dynamics of “small-world” networks*. Nature, 393(6684), pp.440-442.
18. WATTS, D.J. and STROGATZ, S. H., op. cit., pp.440-441.
19. ALBERT, R. and BARABÁSI, A. L., op. cit., p.48-49.
20. WATTS, D. J. and STROGATZ, S. H., op. cit., pp.441-442.
21. LIMA, op. cit., pp.63-72.
22. LIMA, op. cit., pp.14-26.